

RAISE HACKATHON - TRACK VULTR

Inteligencia agéntica con VultronRetriever

Traducción al español del documento técnico del track Vultr

Descripción general

Vultr proporciona la infraestructura de nube e inteligencia artificial para este hackathon. Los equipos que construyan sobre Vultr y lo utilicen como columna vertebral para la recuperación de información, el razonamiento y el despliegue podrán participar en los Premios Vultr.

Este hackathon te reta a ir más allá de un chatbot básico. Buscamos agentes capaces de leer documentos reales, planificar en múltiples pasos y actuar con base en lo que encuentran. Dos servicios de Vultr impulsarán el proyecto:

VultronRetriever

Es el recuperador documental desarrollado por Vultr. Lee una página de forma similar a una persona: interpreta el diseño completo, incluidas tablas, gráficas y documentos escaneados, y devuelve las páginas más relevantes para cada consulta. Puede detectar información que una búsqueda tradicional basada solo en texto podría pasar por alto.

Vultr Serverless Inference

Ofrece modelos de lenguaje de código abierto mediante una API compatible con OpenAI. Basta con dirigir un cliente existente de OpenAI al endpoint de Vultr para comenzar a generar respuestas.

El desafío

Construir un agente empresarial basado en web para un flujo de trabajo del mundo real, cuyas decisiones estén fundamentadas en documentos. La palabra clave es agente: una sola llamada de recuperación y respuesta no es suficiente.

El proyecto debe

- Utilizar los modelos VultronRetriever mediante Vultr Serverless Inference como motor principal de razonamiento del agente empresarial.

Las tres variantes disponibles son:

- [VultronRetriever Prime - Qwen3.5 8B](#)
- [VultronRetriever Core - Qwen3.5 4.5B](#)
- [VultronRetriever Flash - Qwen3.5 0.8B](#)
- Opcionalmente, se pueden utilizar otros agentes o modelos para facilitar el chat, las interacciones de interfaz o tareas secundarias; sin embargo, el flujo empresarial principal debe estar impulsado por modelos VultronRetriever a través de Vultr Serverless Inference.

El proyecto debe mostrar un flujo de trabajo de varios pasos en el que el sistema planifique, recupere información más de una vez cuando sea necesario, llame herramientas, tome decisiones y produzca

un resultado que un equipo real pueda utilizar. El enfoque se centra en operaciones agénticas y el futuro del trabajo en industrias como telecomunicaciones, salud, finanzas y hospitalidad.

Ejemplos del nivel esperado

Telecomunicaciones

Un agente de operaciones de red que ingiere registros de mantenimiento de torres, reportes de interrupciones y acuerdos de nivel de servicio de proveedores; después planifica secuencias de despacho para reparaciones, recupera datos históricos de incidentes para predecir causas raíz, llama herramientas de programación para asignar cuadrillas de campo y genera un reporte de acciones priorizadas con documentación citada.

Salud

Un agente de documentación clínica que lee formularios de ingreso de pacientes, resultados de laboratorio y pólizas de seguro en PDF; planifica qué expedientes adicionales hacen falta, recupera lineamientos clínicos relevantes, llama herramientas de codificación para verificar el cumplimiento de facturación, detecta discrepancias y produce un resumen estructurado con citas exactas de página para el equipo de atención.

Finanzas

Un agente de evaluación de créditos que analiza reportes crediticios, estados de resultados y documentos regulatorios; planifica qué factores de riesgo investigar con mayor profundidad, recupera historiales de casos comparables, llama herramientas de verificación para contrastar datos, emite recomendaciones de aprobación con niveles de confianza y genera un memorando de decisión que cita cada documento fuente.

Hospitalidad

Un agente de revenue management que lee patrones de reservas, hojas de precios de competidores y calendarios de eventos; planifica ajustes dinámicos de tarifas, recupera datos históricos de ocupación, llama herramientas de precios para actualizar tarifas en distintos canales, detecta anomalías como aumentos repentinos de demanda y entrega un brief de estrategia de ingresos con inteligencia de mercado citada.

Expectativas para desarrolladores

Cada equipo debe proporcionar:

- Repositorio en GitHub con instrucciones de instalación y documentación.
- Backend desplegado en Vultr, ya sea en una máquina virtual o mediante servicios de Vultr.
- Uso de los modelos VultronRetriever para la recuperación de documentos.
- Uso de modelos VultronRetriever mediante Vultr Serverless Inference para todos los pasos centrales de razonamiento del modelo.
- URL pública de la demo.
- Video grabado de la demostración.
- Explicación clara de la arquitectura, el flujo del agente y el caso de uso.

Tecnología

- Se puede utilizar cualquier lenguaje o framework.
- Los modelos VultronRetriever mediante Vultr Serverless Inference, compatible con OpenAI, deben utilizarse en todos los pasos principales de razonamiento.
- Se pueden usar otros agentes o modelos para facilitar el chat, la interfaz o tareas secundarias.
- Se otorgarán puntos adicionales por diseños creativos de múltiples agentes, uso de herramientas y manejo sólido de documentos complejos o desordenados del mundo real.

Recursos y documentación

Plataforma y productos de Vultr

- [Documentación de productos de Vultr](#)
- [Documentación de la plataforma Vultr](#)
- [Documentación de soporte de Vultr](#)

API e inferencia de Vultr

- [Endpoints de la API de Vultr](#)
- [Documentación de Vultr Serverless Inference](#)
- [Colección de modelos VultronRetriever en Hugging Face](#)

Estos modelos deben utilizarse mediante Vultr Serverless Inference para el razonamiento central del agente empresarial.

Créditos y elegibilidad

Vultr proporcionará USD 200 en créditos por participante.

Para activar el acceso, cada integrante debe seguir la guía de configuración de cuenta de Vultr: "How to Claim Hackathon Credits - RAISE Hackathon".

Nota importante: Las GPU de Vultr no estarán disponibles para este evento. Todos los trabajos con modelos de lenguaje deben ejecutarse mediante Vultr Serverless Inference.